

Analiza i modelovanje skupa podataka

WELFake

Seminarski rad u okviru kursa
Istraživanje podataka 2
Matematički fakultet

Nenad Dobrosavljević
n.dobrosavljevic01@gmail.com

11. mart 2026.

Sažetak

U radu je izvršena analiza i modelovanje skupa podataka WELFake koji sadrži tekstualne vesti označene kao realne ili lažne. Primenjene su tri metode istraživanja podataka: klasifikacija, klasterovanje i pravila pridruživanja. Cilj rada je uporediti performanse različitih algoritama i ispitati strukturu podataka kroz nadgledane i nenadgledane pristupe.

Sadržaj

1	Uvod	2
2	Opis skupa podataka	2
3	Preprocesiranje podataka	3
3.1	Čišćenje priprema i normalizacija podataka	3
3.2	Reprezentacija pomoću TF-IDF	3
3.3	Redukcija dimenzionalnosti	4
4	Klasifikacija	5
4.1	Reprezentacija podataka	5
4.2	Modeli sa punim skupom atributa	5
4.3	Modeli sa redukovanim skupom atributa	6
4.4	Modeli sa SVD redukcijom	6
4.5	Uporedna analiza rezultata	6
5	Klasterovanje	7
5.1	Određivanje broja klastera	7
5.2	Primena algoritama	7
5.3	Evalvacija i poređenje	8
6	Pravila pridruživanja	8
6.1	Apriori algoritam	8
6.2	FP-Growth algoritam	9
6.3	Poređenje Fake i Real podskupa	9
7	Zaključak	9

1 Uvod

Razvoj metoda za automatsku analizu tekstualnih podataka predstavlja jednu od najznačajnijih oblasti savremenog istraživanja podataka. Sa porastom količine informacija dostupnih putem interneta, posebno kroz digitalne medije i društvene mreže, postaje sve važnije razvijati algoritme koji mogu efikasno analizirati, klasifikovati i interpretirati tekstualni sadržaj.

Jedan od značajnih problema u ovoj oblasti jeste identifikacija lažnih vesti (fake news). Lažne informacije mogu imati ozbiljne društvene, političke i ekonomske posledice, te je automatizovano prepoznavanje takvog sadržaja postalo predmet intenzivnog istraživanja.

U ovom radu analiziran je skup podataka WELFake, koji sadrži tekstualne vesti označene kao realne ili lažne. Skup podataka omogućava primenu različitih metoda istraživanja podataka nad tekstualnim sadržajem, uključujući nadgledane i nenadgledane pristupe.

Cilj rada je primena i poređenje tri različite metode istraživanja podataka:

- klasifikacija,
- klasterovanje,
- pravila pridruživanja.

Kroz klasifikaciju se ispituje mogućnost preciznog razdvajanja realnih i lažnih vesti korišćenjem različitih algoritama mašinskog učenja. Klasterovanjem se analizira prirodna struktura podataka bez korišćenja oznaka klase, dok se pravilima pridruživanja ispituju obrasci ko-pojava pojavljivanja termina u tekstovima.

Rad je organizovan na sledeći način. Nakon opisa skupa podataka i postupka preprocesiranja, prikazani su rezultati klasifikacije sa različitim reprezentacijama atributa. Zatim je sprovedena analiza klasterovanja i evaluacija kvaliteta dobijenih klastera. U završnom delu rada analizirana su pravila pridruživanja i diskutovani su zaključci dobijeni kroz sve primenjene metode.

2 Opis skupa podataka

U ovom radu korišćen je skup podataka *WELFake*, koji predstavlja kombinaciju više javno dostupnih skupova podataka sa ciljem izbegavanja pretreniranosti modela i obezbeđivanja većeg broja tekstualnih instanci za analizu.

Skup podataka sadrži ukupno 72 134 tekstualne vesti, pri čemu je svaka instanca označena kao realna ili lažna vest. Raspodela klase je sledeća:

- 37 106 realnih vesti,
- 35 028 lažnih vesti.

Može se primetiti da je skup podataka gotovo balansiran, što predstavlja povoljnu karakteristiku za primenu klasifikacionih algoritama.

Svaka instanca sadrži sledeće attribute:

- **title** – naslov vesti,
- **text** – sadržaj vesti,
- **label** – ciljna promenljiva (0 – fake, 1 – real).

Podaci su tekstualne prirode i zahtevaju odgovarajuće metode reprezentacije kako bi mogli biti korišćeni u algoritmima mašinskog učenja. Zbog visoke dimenzionalnosti tekstualnog prostora, neophodno je sprovesti postupak preprocesiranja i transformacije podataka pre primene modela.

Skup podataka je javno dostupan putem platforme Kaggle i opisan je u radu [1], a detaljan opis i analiza originalne verzije publikovani su u IEEE Transactions on Computational Social Systems.

3 Preprocesiranje podataka

Tekstualni podaci po svojoj prirodi nisu direktno pogodni za primenu algoritama mašinskog učenja, te je bilo neophodno sprovesti odgovarajući postupak preprocesiranja i transformacije podataka.

3.1 Čišćenje priprema i normalizacija podataka

U početnoj fazi izvršeno je:

- uklanjanje nepotrebne indeksne kolone,
- popunjavanje nedostajućih vrednosti praznim stringovima,
- uklanjanje instanci bez tekstualnog sadržaja (ukoliko postoje),
- spajanje atributa *title* i *text* u jedinstveni atribut *content*.

Spajanjem naslova i sadržaja vesti povećava se količina dostupnog semantičkog signala za modele.

Nad tekstualnim sadržajem primenjene su sledeće transformacije:

- konverzija u mala slova,
- uklanjanje URL adresa,
- uklanjanje specijalnih znakova i interpunkcije,
- uklanjanje viška razmaka.

Cilj ovih transformacija jeste standardizacija zapisa i smanjenje šuma u podacima.

3.2 Reprezentacija pomoću TF-IDF

Kako bi tekstualni podaci bili predstavljeni u numeričkom obliku, primenjena je TF-IDF (Term Frequency–Inverse Document Frequency) transformacija.

TF-IDF omogućava ponderisanje termina u odnosu na njihovu učestalost u dokumentu i u celokupnom skupu podataka, čime se umanjuje značaj često korišćenih, ali informativno slabih termina.


U radu je korišćeno 5000 najznačajnijih atributa dobijenih TF-IDF transformacijom.

3.3 Redukcija dimenzionalnosti


Zbog visoke dimenzionalnosti TF-IDF prostora, primenjena je metoda TruncatedSVD radi projekcije podataka u latentni prostor niže dimenzionalnosti.

Redukcija dimenzionalnosti korišćena je u dve svrhe:

- vizuelna analiza podataka u 2D i 3D prostoru,
- ispitivanje uticaja redukcije atributa na performanse klasifikacionih modela.



Slika 1: 2D projekcija dokumenata nakon SVD redukcije



Slika 2: 3D projekcija dokumenata nakon SVD redukcije

Vizuelna analiza pokazuje značajno preklapanje instanci različitih klasa u niskodimenzionalnom prostoru. Objasnjena varijansa prve dve kom-

ponente je mala, što ukazuje da struktura podataka nije lako separabilna u prostoj projekciji.

Ovakav nalaz sugerije da problem klasifikacije zahteva primenu algoritama koji koriste punu dimenzionalnost prostora atributa.

4 Klasifikacija

U ovom poglavlju analizirana je primena različitih klasifikacionih algoritama nad skupom podataka WELFake.

Podaci su podeljeni na trening i test skup u odnosu 80:20, pri čemu je korišćena stratifikacija kako bi raspodela klasa ostala očuvana u oba skupa.

Evaluacija modela vršena je korišćenjem sledećih metrika:

- Accuracy,
- Precision,
- Recall,
- F1-score.

4.1 Reprezentacija podataka

Za potrebe klasifikacije korišćene su tri različite reprezentacije atributa:

1. TF-IDF reprezentacija sa 5000 atributa (FULL),
2. TF-IDF sa selekcijom 1000 najznačajnijih atributa (SELECT),
3. TF-IDF sa TruncatedSVD redukcijom na 100 komponenti (SVD).

Cilj je bio ispitati uticaj dimenzionalnosti prostora atributa na performanse modela.

4.2 Modeli sa punim skupom atributa

Testirani su sledeći algoritmi:

- Logistic Regression,
- Linear SVM,
- Multinomial Naive Bayes,
- SGD Classifier,
- Random Forest.

Rezultati su prikazani u Tabeli 1.

Tabela 1: Rezultati klasifikacije – FULL reprezentacija

Model	Accuracy	Precision	Recall	F1-score
Logistic Regression	0.9510	0.9484	0.9567	0.9526
Linear SVM	0.9537	0.9517	0.9586	0.9552
Naive Bayes	0.8482	0.8429	0.8663	0.8545
SGD Classifier	0.9496	0.9443	0.9586	0.9514
Random Forest	0.9604	0.9514	0.9728	0.9620

Rezultati pokazuju da Random Forest ostvaruje najbolje performanse, dok linearni modeli postižu vrlo konkurentne rezultate. Multinomial Naive Bayes pokazuje slabije performanse u poređenju sa ostalim modelima.

4.3 Modeli sa redukovanim skupom atributa

U ovoj fazi korišćen je redukovani TF-IDF prostor sa 1000 najznačajnijih atributa. Rezultati su prikazani u Tabeli 2.

Tabela 2: Rezultati klasifikacije – SELECT reprezentacija

Model	Accuracy	Precision	Recall	F1-score
Logistic Regression	0.9338	0.9282	0.9443	0.9362
Linear SVM	0.9424	0.9398	0.9488	0.9443
Naive Bayes	0.8574	0.8533	0.8727	0.8629
SGD Classifier	0.9305	0.9220	0.9448	0.9332
Random Forest	0.9609	0.9526	0.9724	0.9624

Može se primetiti da redukcija atributa dovodi do blagog pada performansi kod linearnih modela, dok Random Forest zadržava gotovo identične rezultate kao u slučaju punog skupa atributa. Ovo ukazuje da Random Forest model bolje podnosi smanjenje dimenzionalnosti u poređenju sa linearnim modelima.

4.4 Modeli sa SVD redukcijom

U trećem eksperimentu primenjena je TruncatedSVD redukcija na 100 latentnih komponenti. Rezultati su prikazani u Tabeli 3.

Tabela 3: Rezultati klasifikacije – SVD reprezentacija

Model	Accuracy	Precision	Recall	F1-score
Logistic Regression	0.9065	0.9075	0.9111	0.9093
Linear SVM	0.9076	0.9097	0.9108	0.9102
SGD Classifier	0.9056	0.9001	0.9183	0.9092
Random Forest	0.9253	0.9209	0.9352	0.9280

4.5 Uporedna analiza rezultata

Analizom rezultata može se uočiti da najbolji ukupni rezultat ostvaruje Random Forest model u FULL i SELECT konfiguraciji, sa F1-score vrednostima većim od 0.96.

Linearni modeli (Logistic Regression, Linear SVM i SGD) postižu vrlo visoke performanse u visoko-dimenzijskom TF-IDF prostoru, što je u skladu sa teorijskim očekivanjima da linearni klasifikatori dobro funkcionišu nad tekstualnim podacima.

Smanjenje broja atributa na 1000 dovodi do blagog pada performansi, dok SVD redukcija na 100 komponenti uzrokuje značajniji pad tačnosti. Ovo ukazuje da deo diskriminativne informacije biva izgubljen projekcijom u latentni prostor.

Zaključno, može se reći da visoka dimenzionalnost tekstualnog prostora predstavlja prednost za klasifikaciju, dok agresivna redukcija dimenzionalnosti može negativno uticati na performanse modela.

5 Klasterovanje

U ovom poglavlju primenjene su nenadgledane metode u cilju analize prirodne strukture podataka bez korišćenja oznaka klasa.

Zbog visoke dimenzionalnosti i velikog broja instanci, klasterovanje je sprovedeno nad podskupom od 10 000 slučajno odabranih instanci. Ovakav pristup omogućava značajno smanjenje vremena izvršavanja algoritama, uz zadržavanje reprezentativnosti skupa.

5.1 Određivanje broja klastera

Za određivanje optimalnog broja klastera korišćena je Silhouette analiza u opsegu od 2 do 10 klastera.

Najviša Silhouette vrednost dobijena je za $k = 4$, te je taj broj klastera korišćen u daljoj analizi.



Slika 3: Silhouette analiza za različite vrednosti parametra k

5.2 Primena algoritama

Testirani su sledeći algoritmi klasterovanja:

- KMeans,
- MiniBatch KMeans,
- Agglomerative Clustering,
- Gaussian Mixture Model,
- DBSCAN.

Evaluacija kvaliteta klastera vršena je korišćenjem sledećih metrika:

- Silhouette score,
- Davies-Bouldin indeks,
- Calinski-Harabasz indeks,
- Adjusted Rand Index (ARI),

- Normalized Mutual Information (NMI).

Tabela 4: Rezultati klasterovanja

Model	Silhouette	DB	CH	ARI	NMI
KMeans	0.0725	2.996	306.65	0.021	0.056
MiniBatchKMeans	0.0610	3.590	256.72	0.016	0.041
Agglomerative	0.0537	3.588	225.75	0.013	0.039
Gaussian Mixture	0.0165	5.073	157.45	0.064	0.058
DBSCAN	–	–	–	–	–

5.3 Evaluacija i poredenje

Dobijene Silhouette vrednosti su relativno niske, što ukazuje na slabu separabilnost klastera u prostoru atributa. Takođe, niske vrednosti ARI i NMI metrika pokazuju da klasteri ne odgovaraju jasno postojećim klasama (real vs. fake).

Ovakav rezultat sugerise da struktura podataka nije prirodno podeljena prema oznakama klasa, već da razdvajanje realnih i lažnih vesti zahteva nadgledani pristup.

DBSCAN algoritam nije uspeo da formira više stabilnih klastera, što dodatno potvrđuje da podaci ne sadrže jasno definisane gustinske grupe u redukovanom prostoru.

6 Pravila pridruživanja

U ovom poglavlju analizirani su obrasci ko-pojavaivanja termina unutar tekstualnih dokumenata primenom metoda za otkrivanje pravila pridruživanja.

Tekstualni podaci transformisani su u transakcioni format, gde svaka vest predstavlja jednu transakciju, a termini u dokumentu predstavljaju stavke (iteme).

Analiza je sprovedena nad podskupom od 10 000 instanci zbog visoke dimenzionalnosti prostora atributa.

6.1 Apriori algoritam

Za generisanje frequent itemset-ova korišćen je Apriori algoritam sa definisanim minimalnim pragovima podrške i pouzdanosti.

Ukupno je generisano 2 657 frequent itemset-ova i 2 376 pravila pridruživanja.

Najviši lift vrednosti dobijene su za termine koji se gotovo uvek pojavljuju zajedno, kao što su:

- (comey, director) $\Rightarrow$ (james, fbi),
- (putin) $\Rightarrow$ (vladimir),
- (states) $\Rightarrow$ (united).

Visoke lift vrednosti (iznad 60) ukazuju na snažnu povezanost termina koji semantički pripadaju istoj temi.

6.2 FP-Growth algoritam

Radi poređenja efikasnosti i konzistentnosti rezultata, primenjen je i FP-Growth algoritam.

Broj dobijenih pravila identičan je broju pravila dobijenih Apriori algoritmom, što potvrđuje konzistentnost pristupa.

6.3 Poređenje Fake i Real podskupa

Pravila su dodatno analizirana odvojeno za podskup lažnih i realnih vesti.

U podskupu lažnih vesti generisano je 2 525 pravila, dok je u podskupu realnih vesti generisano svega 93 pravila.

Kod lažnih vesti uočena je snažna ko-pojava političkih termina, naročito:

- (donald, clinton) $\Rightarrow$ (trump, hillary),
- (clinton, presidential) $\Rightarrow$ (hillary, democratic).

Ovakvi obrasci ukazuju na tematsku homogenost lažnih vesti i ponavljanje specifičnih političkih narativa.

Sa druge strane, realne vesti pokazuju manji broj jakih pravila, što sugerise veću tematsku raznovrsnost i manju koncentraciju termina.

Analiza pravila pridruživanja pokazuje da se lažne vesti karakterišu izraženim obrascima ponavljanja određenih termina i tematskom koncentracijom, dok realne vesti pokazuju veću raznovrsnost sadržaja.

Ovi nalazi dodatno potvrđuju rezultate klasifikacije i ukazuju na postojanje jasnih tekstualnih obrazaca koji razlikuju dve klase.

7 Zaključak

U ovom radu izvršena je sveobuhvatna analiza skupa podataka WEL-Fake primenom tri različite metode istraživanja podataka: klasifikacije, klasterovanja i pravila pridruživanja.

Rezultati klasifikacije pokazali su da su tekstualni podaci veoma pogodni za nadgledane metode. Linearni modeli i Random Forest ostvarili su visoke vrednosti tačnosti i F1-mere, pri čemu je Random Forest postigao najbolje ukupne rezultate. Eksperimenti sa redukcijom dimenzionalnosti pokazali su da agresivna redukcija atributa može dovesti do gubitka diskriminativnih informacija, dok visoko-dimenzionalna TF-IDF reprezentacija daje najbolje performanse.

Sa druge strane, rezultati klasterovanja pokazali su da podaci nemaju jasno izraženu prirodnu strukturu koja odgovara klasama realnih i lažnih vesti. Niske vrednosti Silhouette, ARI i NMI metrika ukazuju da se klase značajno preklapaju u prostoru atributa i da nenadgledane metode nisu dovoljne za jasno razdvajanje dokumenata.

Analiza pravila pridruživanja dodatno je osvetlila strukturu podataka. Lažne vesti pokazuju izraženiju tematsku koncentraciju i snažnije obrasce ko-pojavljivanja političkih termina, dok su realne vesti raznovrsnije. Ovaj nalaz pruža dodatno objašnjenje zašto klasifikacioni modeli mogu uspešno razlikovati dve klase – postoje jasni tekstualni obrasci, ali oni nisu dovoljno izraženi da bi se spontano formirali klasteri bez nadzora.

Na osnovu sprovedene analize može se zaključiti da problem detekcije lažnih vesti predstavlja tipičan primer zadatka klasifikacije, gde nadgledani pristup daje znatno bolje rezultate od nenadgledanog.

Literatura

- [1] Prashant Verma and Nitin Agrawal. Welfake: A word embedding-based fake news detection dataset. *IEEE Transactions on Computational Social Systems*, 2021.